

Weibull 2パラメータ分布の 予測区間を求める

「推定値はどこまで信用できるの？」—— その答えが信頼区間です。
初心者でもわかるように、数式とPythonコードで丁寧に解説します。

— 目次 —

- 01 Weibull分布って何？ — 基本をおさらい
- 02 パラメータの推定 — 最尤推定法(MLE)
- 03 推定値の不確かさ — Fisher情報量と共分散行列
- 04 CDF信頼区間 — Delta法 + Logit変換
- 05 実装ステップ — Pythonで動かす
- 06 信頼区間 vs 予測区間 — 何が違う？
- 07 打切りデータの扱い
- 08 まとめ & 参考文献

01

Weibull分布って何？

Weibull（ワイブル）分布は、**製品がいつ壊れるか**を記述するための確率分布です。信頼性工学で最もよく使われます。

2つのパラメータ

WEIBULL CDF（累積故障率）

$$F(t) = 1 - \exp[-(t / \alpha)^\beta]$$

パラメータ	名前	意味	影響
α	尺度パラメータ (特性寿命)	$F(\alpha) = 63.2\%$ となる時刻	大きい → 長寿命
β	形状パラメータ	故障率の時間変化の傾き	$\beta < 1$: 初期故障型 $\beta = 1$: 偶発故障 (指数分布) $\beta > 1$: 摩耗故障型

💡 なぜWeibullが便利？

β の値を変えるだけで、初期故障（バスタブ曲線の左）から摩耗故障（右）まで表現できます。1つの数式で多様な故障パターンをカバーできるのが最大の強みです。

位置-尺度パラメトリゼーション

数学的な計算では、対数変換した形がよく使われます。

変換

$$\mu = \ln(\alpha) \quad \sigma = 1 / \beta \quad z = (\ln(t) - \mu) / \sigma$$

この変換により、Weibull分布は**最小極値分布（SEV）**の位置-尺度族になり、正規分布と同じような統計理論が使えるようになります。

02

パラメータの推定 — 最尤推定法(MLE)

「どの α, β がデータに一番合うか？」を見つけるのが**最尤推定法 (MLE: Maximum Likelihood Estimation)** です。

対数尤度関数

打ち切りデータあり の対数尤度

$$L(\mu, \sigma) = \sum_{\text{故障}} [-\ln(\sigma) - \ln(t) + z - \exp(z)] + \sum_{\text{打ち切り}} [-\exp(z)]$$

🤔 直感的に理解すると…

故障データ：「この時刻に壊れた」→ 確率密度 $f(t)$ の対数を足す

打ち切りデータ：「この時刻までは生きていた」→ 生存関数 $S(t)$ の対数を足す

全データの「尤もらしさ」を最大にする μ, σ を見つけるのがMLEです。

MLEの解き方

対数尤度を μ と σ で偏微分して0とおきます。2パラメータの場合は閉じた形の解がないため、**数値最適化**（ニュートン法、L-BFGS-B等）で解きます。

```

# Pythonでの MLE 実装例

from scipy.optimize import minimize
import numpy as np

def neg_log_likelihood(params, t_fail, t_cens):
    mu, sigma = params
    if sigma <= 0: return 1e30
    ll = 0.0
    for t in t_fail:
        z = (np.log(t) - mu) / sigma
        ll += -np.log(sigma) - np.log(t) + z - np.exp(z)
    for t in t_cens:
        z = (np.log(t) - mu) / sigma
        ll += -np.exp(z)
    return -ll # 最小化 = 最大化の符号反転

result = minimize(neg_log_likelihood,
                  x0=[4.5, 0.6], # 初期値
                  args=(failures, censored),
                  method='L-BFGS-B',
                  bounds=[(None, None), (1e-10, None)])
mu_hat, sigma_hat = result.x

```

03

推定値の不確かさ — Fisher情報量と共分散行列

MLEで求めた $\hat{\mu}$, $\hat{\sigma}$ はあくまで推定値です。データが変われば別の値になります。「推定値のバラつき」を定量化するのが**共分散行列**です。

Fisher情報量行列

FISHER情報量行列

$$I(\theta) = -E[\partial^2 L / \partial \theta \partial \theta^T]$$

実際には期待値の代わりに、MLE点での観測ヘッセ行列を使います。

共分散行列の推定

$$\text{Cov}(\hat{\mu}, \hat{\sigma}) \approx [-\partial^2 L / \partial \theta \partial \theta^T]^{-1} = H^{-1}$$

⚠ 注意: これは漸近近似です

この共分散行列はサンプルサイズが十分に大きいときに正確です。小標本（ $n < 20$ 程度）ではプロファイル尤度法のほうがより正確な信頼区間を与えます。

数値的な計算方法

対数尤度関数の2階偏微分を中心差分法で数値計算します。

中心差分法

$$\partial^2 L / \partial \mu^2 \approx [L(\mu+h) - 2L(\mu) + L(\mu-h)] / h^2$$

交差微分（ $\partial^2 L / \partial \mu \partial \sigma$ ）も同様に4点差分で計算し、 2×2 のヘッセ行列 H を

作り、その逆行列が共分散行列になります。

共分散行列の構造

$$\text{Cov} = H^{-1} = \begin{vmatrix} \text{Var}(\hat{\mu}) & \text{Cov}(\hat{\mu}, \hat{\sigma}) \\ \text{Cov}(\hat{\mu}, \hat{\sigma}) & \text{Var}(\hat{\sigma}) \end{vmatrix}$$

04

CDF信頼区間 — Delta法 + Logit変換

ここが本資料の**核心**です。「ある時刻 t での累積故障率 $F(t)$ の信頼区間」を求めます。

1

点推定値を計算

$z = (\ln(t) - \hat{\mu}) / \hat{\sigma}$ を計算し、 $\hat{F} = 1 - \exp(-\exp(z))$ を得る。

2

Delta法で $\hat{F}$ の分散を求める

F はパラメータ (μ, σ) の非線形関数です。**Delta法**（テイラー展開の1次近似）で分散を伝播させます。

$$\partial F / \partial \mu = -\phi / \sigma$$

$$\partial F / \partial \sigma = -\phi \times z / \sigma$$

$$\text{ただし } \phi = \exp(-\exp(z)) \times \exp(z) = (1 - F) \times \exp(z)$$

$$\text{Var}(\hat{F}) = [\partial F / \partial \mu, \partial F / \partial \sigma] \times \text{Cov} \times [\partial F / \partial \mu, \partial F / \partial \sigma]^T$$

3

Logit変換で区間を (0, 1) に収める

F の信頼区間をそのまま「 $\hat{F} \pm z_{\alpha/2} \times \text{SE}(F)$ 」で計算すると、0未満や1超えになることがあります。**Logit変換**で回避します。

$$g = \ln(\hat{F} / (1 - \hat{F})) \quad \leftarrow \text{Logit変換}$$

$$\text{SE}(g) = \text{SE}(\hat{F}) / [\hat{F} \times (1 - \hat{F})]$$

$$g \text{ の信頼区間: } [g - z_{\alpha/2} \times \text{SE}(g), g + z_{\alpha/2} \times \text{SE}(g)]$$

4

逆変換で F の信頼区間に戻す

$$F_{\text{lower}} = 1 / (1 + \exp(-g_{\text{lower}}))$$

$$F_{\text{upper}} = 1 / (1 + \exp(-g_{\text{upper}}))$$

Logit変換のおかげで、信頼区間は自動的に0～1の範囲に収まります。

💡 なぜLogit変換？

CDFの値は0～1の範囲に限られますが、正規近似による信頼区間はこの制約を無視してしまいます。Logit変換は F を実数全体に写像し、正規近似を適用した後に戻すことで、物理的に意味のある区間を保証します。JMP、Minitab等の商用ソフトでもこの手法が標準です。




図1: Weibull CDF とその95%信頼区間 (Delta法+Logit変換)

05

実装ステップー Pythonで動かす

ここまでの理論を、実際のコードに落とし込みます。

```

import numpy as np
from scipy import optimize, stats

# ---- データ ----
failures = np.array([15, 25, 35, 50, 65, 80, 100, 120, 145])
censored = np.array([30, 60, 90, 150, 200])

# ---- Step 1: MLE ----
def neg_ll(params):
    mu, sigma = params
    if sigma <= 0: return 1e30
    ll = 0.0
    for t in failures:
        z = (np.log(t) - mu) / sigma
        ll += -np.log(sigma) - np.log(t) + z - np.exp(z)
    for t in censored:
        z = (np.log(t) - mu) / sigma
        ll += -np.exp(z)
    return -ll

res = optimize.minimize(neg_ll, [4.5, 0.6],
                        method='L-BFGS-B',
                        bounds=[(None, None), (1e-10, None)])

mu_hat, sigma_hat = res.x
alpha_hat = np.exp(mu_hat)
beta_hat = 1.0 / sigma_hat

# ---- Step 2: ヘッセ行列 → 共分散行列 ----
h = 1e-5
H = np.zeros((2, 2))
f0 = neg_ll([mu_hat, sigma_hat])

#  $\partial^2 L / \partial \mu^2$ 
H[0,0] = (neg_ll([mu_hat+h, sigma_hat]) - 2*f0
          + neg_ll([mu_hat-h, sigma_hat])) / h**2

#  $\partial^2 L / \partial \sigma^2$ 
H[1,1] = (neg_ll([mu_hat, sigma_hat+h]) - 2*f0
          + neg_ll([mu_hat, sigma_hat-h])) / h**2

#  $\partial^2 L / \partial \mu \partial \sigma$ 
H[0,1] = H[1,0] = (

```

```

    neg_ll([mu_hat+h, sigma_hat+h])
- neg_ll([mu_hat+h, sigma_hat-h])
- neg_ll([mu_hat-h, sigma_hat+h])
+ neg_ll([mu_hat-h, sigma_hat-h])
) / (4 * h**2)

Cov = np.linalg.inv(H)

# ---- Step 3: ある時刻 t での CDF信頼区間 ----
def cdf_confidence_interval(t, conf=0.95):
    zc = stats.norm.ppf((1 + conf) / 2) # = 1.96
    z = (np.log(t) - mu_hat) / sigma_hat
    F = 1 - np.exp(-np.exp(z))

    # Delta法: 勾配ベクトル
    phi = np.exp(-np.exp(z)) * np.exp(z)
    grad = np.array([-phi/sigma_hat, -phi*z/sigma_hat])
    se_F = np.sqrt(grad @ Cov @ grad)

    # Logit変換
    g = np.log(F / (1 - F))
    se_g = se_F / (F * (1 - F))
    g_lo = g - zc * se_g
    g_hi = g + zc * se_g

    # 逆変換
    F_lo = 1 / (1 + np.exp(-g_lo))
    F_hi = 1 / (1 + np.exp(-g_hi))
    return F, F_lo, F_hi

# ---- 計算例 ----
F, F_lo, F_hi = cdf_confidence_interval(100)
print(f"t=100: F={F:.4f}, 95%CI=[{F_lo:.4f}, {F_hi:.4f}]")

```

実行結果の例

t=100: F=0.5265, 95%CI=[0.3030, 0.7399]

→ 「時刻100での累積故障率は約53%で、95%の信頼度で30%～74%

の範囲にある」と解釈します。

06

信頼区間 vs 予測区間 — 何が違う？

この2つは混同されやすいですが、答えている質問が違います。

	信頼区間 (Confidence Interval)	予測区間 (Prediction Interval)
質問	真の $F(t)$ はどの範囲？	次の1個はいつ壊れる？
不確かさの源	パラメータ推定のバラツキのみ	パラメータ推定 + 個体の確率的バラツキ
幅	狭い ($n \rightarrow \infty$ で 0 に収束)	広い ($n \rightarrow \infty$ でも残る)
用途	母集団のCDFの推定精度を示す	将来のデータの範囲を予測する

⚠ 本資料で扱っているのは「信頼区間」です

本資料のDelta法+Logit変換で求めているのはCDFの**信頼区間**（パラメータの不確かさに起因する区間）です。実務では「CDF信頼区間」「予測区間」を広い意味で「予測区間」と呼ぶことがありますが、統計学的には区別が重要です。

予測区間を求めるには？

将来の1個の寿命 T_{new} の予測区間は、パラメトリックブートストラップや、MVNサンプリング（多変量正規分布からパラメータをサンプリング → 各パラメータでWeibull分位点を計算 → 分位点のパーセンタイル）で求めます。

```
# ---- MVNサンプリングによる予測区間 ----
rng = np.random.default_rng(42)
n_sim = 5000

# パラメータの不確かさをサンプリング
theta_samples = rng.multivariate_normal(
    mean=[mu_hat, sigma_hat], cov=Cov, size=n_sim
)

# 各パラメータセットで 新しい寿命を1つサンプリング
T_pred = []
for mu_s, sigma_s in theta_samples:
    if sigma_s <= 0: continue
    # Weibull乱数 = alpha * (-ln(U))^(1/beta)
    u = rng.random()
    T_new = np.exp(mu_s) * (-np.log(u)) ** sigma_s
    T_pred.append(T_new)

T_pred = np.array(T_pred)
PI_lo = np.percentile(T_pred, 2.5)
PI_hi = np.percentile(T_pred, 97.5)
print(f"95% 予測区間: [{PI_lo:.1f}, {PI_hi:.1f}]")
```

信頼区間と予測区間の比較例

信頼区間（ $t=100$ での $F(t)$ ）: [0.303, 0.740] — CDFの推定精度

予測区間（次の1個の寿命）: [5.2, 374.8] — 次の製品がいつ壊れるかの

範囲

→ 予測区間のほうが大幅に広いことがわかります。

07

打切りデータの扱い

信頼性試験では、試験終了時にまだ壊れていないデータ（打切りデータ）が頻繁に発生します。

経験的CDF — Johnson調整ランク法

打切りデータがある場合、単純にランク付けすると累積故障率が過大評価されます。**Johnson調整ランク法**で正しく計算します。

1

全データを時刻順にソート

故障データと打切りデータを混ぜて昇順に並べます。同時刻の場合は故障を先にします。

2

故障ごとにランク増分を計算

$$\text{増分} = (n + 1 - \text{前のランク}) / (\text{残りデータ数} + 1)$$

打ち切りデータはスキップしますが、「残りデータ数」には影響します。

3

Bernard近似でメジアンランクに変換

$$\hat{F} = (\text{ランク} - 0.3) / (n + 0.4)$$

ここで n は**全データ数**（故障 + 打ち切り）です。

💡 打ち切りの効果

打ち切りデータがあると、その時刻以降の故障のランク増分が大きくなります。つまり「この時刻まで生きていた情報」がリスクセットの減少として反映されます。JMP、ReliaSoftと同じ方法です。

MLE への影響

MLEの対数尤度関数に打ち切りデータを含めれば、パラメータ推定は自動的に打ち切りを考慮します。累積故障率のプロットでは**故障データのみ**をメジアンランクで表示します（打ち切りデータはプロットしません）。

まとめ & 参考文献

全体の流れ



図2: Weibull CDF信頼区間の計算フロー

覚えておくべき3つのポイント

① Delta法は「テイラー展開1次」の分散伝播

非線形関数 $F(\mu, \sigma)$ の分散を、勾配ベクトルと共分散行列から近似計算する手法です。

② Logit変換で区間を $(0, 1)$ に保証

CDFの値域制約を満たす信頼区間を自然に作れます。JMP/Minitab等と同じ方法です。

③ 2パラメータは μ と σ の共分散が効く

β 固定の場合と違い、2パラメータでは $\hat{\mu}$ と $\hat{\sigma}$ の相関も信頼区間の幅に影響します。 $\text{Cov}(\hat{\mu}, \hat{\sigma}) \neq 0$ が一般的です。

参考文献

著者	書籍名	備考
Meeker & Escobar (1998)	Statistical Methods for Reliability Data	Delta法+Logit変換の原典。最も重要な参考書。
Lawless (2003)	Statistical Models and Methods for Lifetime Data	MLE理論とプロファイル尤度の詳細。
Nelson (1982)	Applied Life Data Analysis	実務向け。打切りデータの扱いが詳しい。
Johnson (1964)	The Statistical Treatment of Fatigue Experiments	Johnson調整ランク法の原典。

Weibull 2パラメータ 予測区間 勉強会資料

信頼性工学 社内勉強会用